

Maszyna Boltzmann - symulacja układu

Maciej Obara, Maciej Mak

13 czerwca 2021

Spis treści

1	Wstęp	2
2	Zastosowania RBM	2
3	Trenowanie sieci neuronowej	3
	Literatura	4

1 Wstęp

Ograniczona maszyna boltzmann to sieć neuronowa oparta w pewnym stopniu na prawdopodobieństwie, składająca się z 2 warstw; *warstwy widocznej*, której wartości są znane i ustawiamy je samodzielnie oraz z *warstwy ukrytej* czyli wartości których nie znamy i próbujemy nauczyć tą sieć. Dodatkowo przy każdej aktywacji takiego neuronu dodawana jest *jednostka odchylenia*, która jest stała dla każdego wejścia.

Ważną charakterystyką ograniczonej maszyny boltzmann jest brak komunikacji pomiędzy węzłami na tym samym poziomie, każdy węzeł działa niezależnie od sąsiadów, węzeł z warstwy widocznej przekazuje swój wynik do każdego węzła z warstwy ukrytej. Pozwala to uniknąć zaburzeń neuronów związanych ze klasyfikacją danych wejściowych z innymi danymi wejściowymi. Dodatkowo możemy przez to używać bardziej zaawansowanych algorytmów uczenia takich jak rozbieżność kontrastowa.

Ograniczoną maszynę Boltzmann, jak każdą inną sieć neuronową możemy podzielić na kilka etapów obliczeniowych. Pierwszym z nich jest znalezienie macierzy wag - trenowanie sieci neuronowej. Drugim etapem jest testowanie na podstawie innych danych oraz znalezienie odpowiednich cech jakie wyróżnił wytrenowany przez nas algorytm. Ograniczona maszyna Boltzmann pozwala nam również szukać widocznych neuronów (danych które zwykle wprowadza użytkownik) posiadając tylko neurony ukryte.

2 Zastosowania RBM

Sieci neuronowe wykorzystywane są do wielu zadań przy których konwencjonalne podejście jest mało praktyczne. Jednym z takich zastosowań jest rozpoznawanie odręcznego pisma i jego konwersja na dokument tekstowy. Ponadto algorytm taki potrafi dostosować się do użytkownika i z czasem rozpoznawać jego styl pisma efektywniej i dokładniej. Ma to zastosowanie w tablicach interaktywnych oraz smartfonach.

Najczęściej algorytmy sztucznej inteligencji wykorzystywane są w celu rozpoznania jakiegoś schematu w danych które otrzymują. Podczas treningu kontrolujemy dane wejściowe w celu nauczania algorytmu rozpoznawania interesujących nas danych. Ma to szerokie zastosowanie, algorytm może rozpoznawać mowę w dźwięku, gatunki zwierząt w zdjęciach, choroby z listy objawów.

Do podstawowych zastosowań ograniczonej maszyny Boltzmann zaliczamy różne metody regresji takie jak regresja liniowa czy regresja logistyczna. Innym zastosowaniem tej sztucznej sieci neuronowej jest filtrowanie zespołowe, uczenie schematów czy modelowanie tematyczne.

3 Trenowanie sieci neuronowej

Trenowanie sieci neuronowej jest elementem, który ma na celu dopasowanie wag do odpowiednich danych wejściowych. Obliczenia dokonują się na podstawie kontrastowej rozbieżności (ang. *Contrastive divergence*), która ma na celu dopasowanie wag przez różnice rzeczywistego wyniku działania algorytmu z "wirtualnym" wynikiem wygenerowanym na podstawie danych wyuczonych przez algorytm. Całość jest ograniczana przez tzw. współczynnik uczenia, który mówi nam o ile algorytm powinien zmniejszyć różnicę otrzymaną z CD. Etap trenowania następuje w określonej liczbie iteracji, które w algorytmach sztucznej inteligencji nazywane są epokami (ang. *epochs*).

Operacje trenowania macierzy najwygodniej przedstawić na macierzach. Za pomocą operacji transpozycji czy mnożenia macierzowego można zaoszczędzić sporo czasu na opracowywanie algorytmu RBM. Do treningu będzie potrzebna funkcja sigmoid, która przyjmuje wartości od 0 do 1, a zmiana pomiędzy nimi następuje dla argumentów bliskich zeru.

Dodatnia faza kontrastowej rozbieżności jest obliczana za pomocą mnożenia macierzowego danych treningowych i macierzy wag. Wynik tej operacji jest następnie przepuszczany przez funkcję sigmoid, która oblicza prawdopodobieństwo aktywacji danego ukrytego neurona.

Ujemna faza kontrastowej rozbieżności jest obliczana za pomocą mnożenia uzyskanych ukrytych neuronów z transponowaną macierzą wag. Wynik tej operacji jest następnie przepuszczany przez funkcję sigmoid, która oblicza prawdopodobieństwo aktywacji wirtualnych widocznych neuronów. Nie muszą one być identyczne z naszymi danymi treningowymi.

Do aktualizacji wag za pomocą kontrastowej rozbieżności potrzebujemy danych treningowych wymnożonych przez macierz aktywacji oraz macierzy wirtualnych danych treningowych (obliczonych przez nasz algorytm) wymnożonej przez ich macierzy aktywacji. Różnicę tych macierzy mnożymy przez współczynnik uczenia, a każdy element macierzy dzielimy przez liczbę wszystkich wierszy danych treningowych.

Uwagi Wektor biasów został tutaj umieszczony wertykalnie oraz horyzontalnie obok macierzy wag. Dzięki takiemu zastosowaniu możemy używać wektora biasów tylko przez mnożenie macierzy oraz jej transpozycję. Dodatkowo biasy są w każdej iteracji poprawiane do wartości 1, żeby nie zostały zaburzone przez operację funkcji sigmoid.

Wagi są wybierane losowo. Powoduje to czasami otrzymanie odwrotnych wyników przy następnym testowaniu maszyny. Jednak ze względu na brak warunków początkowych dla wag dla naszego przykładu możemy założyć, że dane testowe są zgodne z losowymi przykładami wag.

Literatura

- [1] Chris Nicholson. A beginner's guide to restricted boltzmann machines (rbms).
<https://wiki.pathmind.com/restricted-boltzmann-machine?fbclid=IwAR1uHntmV9zlrQpzV4oAaVA-YAKqhYI2QqGMz5okp5FtT49ZKezXwvnAE3E>.
- [2] Edwin Chen. Introduction to restricted boltzmann machines. http://blog.echen.me/2011/07/18/introduction-to-restricted-boltzmann-machines/?fbclid=IwAR1jPRGT3pFLPpI31-Ixl_cEs4vXQqD43n1gqGfjN089XGQA1gz98jAoEX0.
- [3] Prerna Sodani. Restricted boltzmann machine and its application. <https://www.latentview.com/blog/restricted-boltzmann-machine-and-its-application/>.