

# Maszyna Boltzmann - symulacja układu

Maciej Obara, Maciej Mak

17 czerwca 2021

## Spis treści

<b>1</b>	<b>Wstęp</b>	<b>2</b>
<b>2</b>	<b>Zastosowania RBM</b>	<b>2</b>
<b>3</b>	<b>Trenowanie sieci neuronowej</b>	<b>3</b>
<b>4</b>	<b>Testowanie sieci neuronowej</b>	<b>4</b>
<b>5</b>	<b>Przykład użycia RBM</b>	<b>4</b>
<b>6</b>	<b>Wyniki</b>	<b>4</b>
6.1	Przypadek 1 . . . . .	5
	Wykres 1 . . . . .	5
6.2	Przypadek 2 . . . . .	6
	Wykres 2 . . . . .	6
<b>7</b>	<b>Wnioski</b>	<b>7</b>
	<b>Literatura</b>	<b>7</b>

# 1 Wstęp

**Ograniczona maszyna boltzmannna** to sieć neuronowa oparta w pewnym stopniu na prawdopodobieństwie, składająca się z 2 warstw; *warstwy widocznej*, której wartości są znane i ustawiamy je samodzielnie oraz z *warstwy ukrytej* czyli wartości których nie znamy i próbujemy nauczyć tą sieć. Dodatkowo przy każdej aktywacji takiego neuronu dodawana jest *jednostka odchylenia*, która jest stała dla każdego wejścia.

Ważną charakterystyką ograniczonej maszyny boltzmannna jest brak komunikacji pomiędzy węzłami na tym samym poziomie, każdy węzeł działa niezależnie od sąsiadów, węzeł z warstwy widocznej przekazuje swój wynik do każdego węzła z warstwy ukrytej. Pozwala to uniknąć zaburzeń neuronów związanych ze klasyfikacją danych wejściowych z innymi danymi wejściowymi. Dodatkowo możemy przez to używać bardziej zaawansowanych algorytmów uczenia takich jak rozbieżność kontrastowa.

Ograniczoną maszynę Boltzmannna, jak każdą inną sieć neuronową możemy podzielić na kilka etapów obliczeniowych. Pierwszym z nich jest znalezienie macierzy wag - trenowanie sieci neuronowej. Drugim etapem jest testowanie na podstawie innych danych oraz znalezienie odpowiednich cech jakie wyróżnił wytrenowany przez nas algorytm. Ograniczona maszyna Boltzmannna pozwala nam również szukać widocznych neuronów (danych które zwykle wprowadza użytkownik) posiadając tylko neurony ukryte.

# 2 Zastosowania RBM

Sieci neuronowe wykorzystywane są do wielu zadań przy których konwencjonalne podejście jest mało praktyczne. Jednym z takich zastosowań jest rozpoznawanie odręcznego pisma i jego konwersja na dokument tekstowy. Ponadto algorytm taki potrafi dostosować się do użytkownika i z czasem rozpoznawać jego styl pisma efektywniej i dokładniej. Ma to zastosowanie w tablicach interaktywnych oraz smartfonach.

Najczęściej algorytmy sztucznej inteligencji wykorzystywane są w celu rozpoznania jakiegoś schematu w danych które otrzymują. Podczas treningu kontrolujemy dane wejściowe w celu nauczania algorytmu rozpoznawania interesujących nas danych. Ma to szerokie zastosowanie, algorytm może rozpoznawać mowę w dźwięku, gatunki zwierząt w zdjęciach, choroby z listy objawów.

Do podstawowych zastosowań ograniczonej maszyny Boltzmannna zaliczamy różne metody regresji takie jak regresja liniowa czy regresja logistyczna. Innym zastosowaniem tej sztucznej sieci neuronowej jest filtrowanie zespołowe, uczenie schematów czy modelowanie tematyczne.

### 3 Trenowanie sieci neuronowej

Trenowanie sieci neuronowej jest elementem, który ma na celu dopasowanie wag do odpowiednich danych wejściowych. Obliczenia dokonują się na podstawie kontrastowej rozbieżności (ang. *Contrastive divergence*), która ma na celu dopasowanie wag przez różnice rzeczywistego wyniku działania algorytmu z "wirtualnym" wynikiem wygenerowanym na podstawie danych wyuczonych przez algorytm. Całość jest ograniczana przez tzw. współczynnik uczenia, który mówi nam o ile algorytm powinien zmniejszyć różnicę otrzymaną z CD. Etap trenowania następuje w określonej liczbie iteracji, które w algorytmach sztucznej inteligencji nazywane są epokami (ang. *epochs*).

Operacje trenowania macierzy najwygodniej przedstawić na macierzach. Za pomocą operacji transpozycji czy mnożenia macierzowego można zaoszczędzić sporo czasu na opracowywanie algorytmu RBM. Do treningu będzie potrzebna funkcja sigmoid, która przyjmuje wartości od 0 do 1, a zmiana pomiędzy nimi następuje dla argumentów bliskich zeru.

Dodatnia faza kontrastowej rozbieżności jest obliczana za pomocą mnożenia macierzowego danych treningowych i macierzy wag. Wynik tej operacji jest następnie przepuszczany przez funkcję sigmoid, która oblicza prawdopodobieństwo aktywacji danego ukrytego neurona.

Ujemna faza kontrastowej rozbieżności jest obliczana za pomocą mnożenia uzyskanych ukrytych neuronów z transponowaną macierzą wag. Wynik tej operacji jest następnie przepuszczany przez funkcję sigmoid, która oblicza prawdopodobieństwo aktywacji wirtualnych widocznych neuronów. Nie muszą one być identyczne z naszymi danymi treningowymi.

Do aktualizacji wag za pomocą kontrastowej rozbieżności potrzebujemy danych treningowych wymnożonych przez macierz aktywacji oraz macierzy wirtualnych danych treningowych (obliczonych przez nasz algorytm) wymnożonej przez ich macierzy aktywacji. Różnicę tych macierzy mnożymy przez współczynnik uczenia, a każdy element macierzy dzielimy przez liczbę wszystkich wierszy danych treningowych.

**Uwagi** Wektor biasów został tutaj umieszczony wertykalnie oraz horyzontalnie obok macierzy wag. Dzięki takiemu zastosowaniu możemy używać wektora biasów tylko przez mnożenie macierzy oraz jej transpozycję. Dodatkowo biasy są w każdej iteracji poprawiane do wartości 1, żeby nie zostały zaburzone przez operację funkcji sigmoid.

Wagi są wybierane losowo. Powoduje to czasami otrzymanie odwrotnych wyników przy następnym testowaniu maszyny. Jednak ze względu na brak warunków początkowych dla wag dla naszego przykładu możemy założyć, że dane testowe są zgodne z losowymi przykładami wag.

## 4 Testowanie sieci neuronowej

Testowanie sieci neuronowej jest najłatwiejszym etapem algorytmu ograniczonej maszyny Boltzmann. Najważniejsze jest, żeby było to przeprowadzone po *wytrenowaniu* maszyny przy pomocy danych treningowych. Otrzymany wynik algorytmu jest najbardziej przewidywaną odpowiedzią, która zadowoli użytkownika. Testować maszynę Boltzmann możemy szukając ukryte neurony przy określonych danych testowych lub na odwrót.

Testowanie jest podobne do początkowego etapu trenowania maszyny Boltzmann. Dane użytkownika w postaci macierzy mnożymy przez wytrenowaną macierz wag w celu szukania ukrytych neuronów, lub wytrenowaną, transponowaną macierz wag w celu szukania widocznych neuronów. Następnie obliczamy zero jedynkowe prawdopodobieństwo na podstawie wyników mnożenia macierzy otrzymanych z funkcji sigmoid. Otrzymane dane są najbardziej zbliżone do preferencji użytkownika według zadanych przedtem danych treningowych.

## 5 Przykład użycia RBM

Nasz projekt ograniczonej maszyny Boltzmann o koncepcje biblioteki książek. Użytkownik podaje swoje preferencje w sposób binarny - książka podoba mu się lub nie. Przed tym następuje proces trenowania maszyny oparty na preferencjach innych użytkowników biblioteki. Wynik jest następnie przepuszczony w dodatnią fazę *kontrastowej rozbieżności*, aby znaleźć wspólne cechy pozycji które podał użytkownik (obliczenie ukrytych neuronów) Następnie dane przepuszczamy przez ujemną fazę *kontrastowej rozbieżności*, aby znaleźć inne pozycje które mogą spodobać się użytkownikowi.

Obracowana maszyna Boltzmann zawiera 21 widocznych neuronów, które oznaczają książkowe preferencje użytkownika oraz 4 ukryte, które oznaczają 4 różnych autorów książek. Spodziewamy się w takim razie wyników, które będą zbliżone do preferencji użytkownika na podstawie autorów książek, które mu się podobają. Nie jest to jednak reguła i jak pokazuje praktyka nie zawsze dostaniemy perfekcyjne wyniki.


## 6 Wyniki

Ze względu na losowość początkowych wag, sieć może zwracać inne wyniki pomimo tych samych danych treningowych. Znacząco może różnić się także błąd. Należy zaznaczyć, że błąd nie ma dużego związku z wynikami które otrzymuje użytkownik tzn. błąd może być bardzo podobny dla dwóch przypadków ale ich wyniki będą różne.

## 6.1 Przypadek 1

Najczęściej występujący przypadek, przypisuje wszystkie książki danego autora pod warunkiem, że użytkownik polubił przynajmniej jedną:

Średni błąd wyniósł: 2.7799. Wykres błędu wygląda następująco:



Rysunek 1: Wykres błędu w 1 przypadku

Widzimy, że błąd w pewnym momencie się ustabilizował i powoli malał.

Po przeprowadzonym treningu podaliśmy dane wejściowe i przeprowadziliśmy test. W danych wejściowych użytkownik podał, że lubi:

*Hobbit, Krew elfów, HP: Kamień filozoficzny.*

Algorytm określił że mogą spodobać mu się:


*Hobbit, Władca Pierścieni, Silmarillion, Historia Śródziemia, Krew elfów, Czas pogardy, Chrzest ognia, Wieża Jaskółki, HP: Kamień filozoficzny, HP: Komnata tajemnic, HP: Więzień azkabanu, HP: Czara ognia, HP: Księżę półkrwi, HP: Insignia śmierci.*

Te wyniki odpowiadają temu czego się spodziewaliśmy, mamy 4 autorów oraz 4 węzły ukryte, zakładaliśmy że sieć nauczy się rozpoznawać książkę po autorze i tak właśnie jest.

## 6.2 Przypadek 2

Czasami algorytm nie działa tak jak byśmy się tego spodziewali, w tym przypadku widzimy że sieć nie powiązała do końca książek z autorami, jeden węzeł ma pewną nieznaną dla nas zależność która zmienia znacząco wynik.

Średni błąd wyniósł: 3.0233. Wykres błędu wygląda następująco:



Rysunek 2: Wykres błędu w 2 przypadku

W tym przypadku błąd się na krótko ustabilizował następnie znowu mocno zmienił.

Po przeprowadzonym treningu (na tych samych danych) podaliśmy te same dane wejściowe i przeprowadziliśmy test. W danych wejściowych użytkownik podał, że lubi:

*Hobbit, Krew elfów, HP: Kamień filozoficzny.*

Algorytm określił że mogą spodobać mu się:

*Hobbit, Władca Pierścieni, Silmarillion, Historia Śródziemia, Przygody Toma Bombadilla, Uczta dla wron, Krew elfów, Czas pogardy, Chrzest ognia, Wieża Jaskółki.*

Pomimo tego że użytkownik lubi książkę o *Harrym Potterze* algorytm poleca *Ucztę Wron*. W zależności od tego co chcemy osiągnąć jest to działanie niepożądane lub wręcz przeciwnie.

Ten niespodziewany wynik pokazuje że zawsze trzeba testować swój algorytm przynajmniej kilka razy aby móc zaobserwować efekty których nie można przewidzieć.

## 7 Wnioski

Zaprezentowana ograniczona maszyna Boltzmanna jest w stanie klasyfikować różne dane za pomocą cech wspólnych. Pokazuje to a jaki sposób można *nauczyć* komputer rozróżniać różne informacje na pomocą wspólnych danych. Podobne algorytmy są często stosowane na różnych portalach oferujących różne filmy, audiobooki czy gry w ramach miesięcznej subskrypcji. Używając ograniczonej maszyny Boltzmanna firma jest w stanie odtrzymać naszą uwagę przy ich produktach oraz skłonić nas do kolejnego zakupu comiesięcznej usługi.

Warto również wspomnieć o wykorzystaniu danych treningowych podczas korzystania z takich usług. Algorytm aplikacji, z której korzystamy przez dłuższy czas, dane dostaje w sposób ciągły, więc minimalizacja błędu między doбором odpowiednich kategorii będzie o wiele lepsza niż w przedstawionym tutaj algorytmie.

## Literatura

- [1] Chris Nicholson. A beginner's guide to restricted boltzmann machines (rbms). <https://wiki.pathmind.com/restricted-boltzmann-machine?fbclid=IwAR1uHntmV9zlrQpzV4oAaVA-YAKqhYI2QqGMz5okp5FtT49ZKezXwvnAE3E>.
- [2] Edwin Chen. Introduction to restricted boltzmann machines. [http://blog.echen.me/2011/07/18/introduction-to-restricted-boltzmann-machines/?fbclid=IwAR1jPRGT3pFLPpI31-Ixl\\_cEs4vXQqD43n1gqGfjN089XGQA1gz98jAoEX0](http://blog.echen.me/2011/07/18/introduction-to-restricted-boltzmann-machines/?fbclid=IwAR1jPRGT3pFLPpI31-Ixl_cEs4vXQqD43n1gqGfjN089XGQA1gz98jAoEX0).
- [3] Prerna Sodani. Restricted boltzmann machine and its application. <https://www.latentview.com/blog/restricted-boltzmann-machine-and-its-application/>.